УДК 629.3.083:658.562:519.25

ПРОГНОЗ РИСКА ПОВТОРНОГО ОБРАЩЕНИЯ ПОСЛЕ РЕМОНТА АВТОМОБИЛЯ, МЕТРИКИ КАЧЕСТВА ПРОГНОЗА И ВЫБОР ПОРОГА УСИЛЕННОГО КОНТРОЛЯ

И.П. Фрелих, В.Г. Мосин

Рассмотрена задача сервиса автомобилей: в момент закрытия заказ-наряда оценить вероятность того, что клиент вернётся с той же неисправностью в течение 30 дней, и для рискованных случаев назначить усиленный контроль качества до выдачи автомобиля. Исследован массив из 3 000 закрытых заказ-нарядов по данным одного из ведущих отечественных автопроизводителей, в котором доля повторных обращений составляет 33,8 %. Сравнены два способа прогноза — логистическая регрессия и случайный лес; для устранения влияния случайного разбиения данных сравнение выполнено на 100 независимых разбиениях выборки на обучающую и проверочную части. Основное внимание уделено метрикам качества прогноза: для каждой из них (доля верных ответов, полнота, точность тревог, F1, ROC-AUC, оценка Брайера) показано, на какой практический вопрос она отвечает, с каким «прогнозом без модели» её следует сравнивать и почему доля верных ответов вводит в заблуждение при неравных классах. Логистическая регрессия оказалась немного, но устойчиво точнее случайного леса: ROC-AUC 0,920 ± 0,011 против 0,914 ± 0,012 (лучше в 97 запусках из 100), оценка Брайера 0,099 против 0,105 (лучше в 99 запусках из 100). Главный фактор повторного обращения — неподтверждённый в ходе работ первоначальный диагноз: такие клиенты возвращаются в 75 % случаев против 15 %. Показано, как перевести метрики на язык загрузки поста контроля: при пороге 0,35 на дополнительную проверку направляется 38 автомобилей из 100, и среди них оказывается 84 % будущих повторных обращений, тогда как выборочная проверка того же числа машин выявила бы около 38 %.

Ключевые слова: техническое обслуживание и ремонт автомобилей, повторное обращение, качество ремонта, усиленный контроль, логистическая регрессия, случайный лес, метрики качества классификации, ROC-AUC, оценка Брайера, порог решения.

Введение

Повторное обращение клиента в сервис с той же неисправностью вскоре после ремонта — один из самых наглядных показателей качества работы станции технического обслуживания. Причины такого возврата хорошо знакомы любому мастеру: неисправность устранена не полностью, первоначальный диагноз оказался ошибочным, установлена бракованная запчасть. Для клиента повторный визит означает ещё один день без автомобиля, для сервиса — работу, которую приходится выполнять повторно за свой счёт. Потребитель при обнаружении недостатков выполненной работы вправе потребовать их безвозмездного устранения [1, ст. 29], а порядок приёмки автомобиля из ремонта и урегулирования разногласий о качестве работ установлен Правилами оказания услуг по техническому обслуживанию и ремонту автомототранспортных средств, действующими с 1 сентября 2025 г. [2].

С позиций системы менеджмента качества повторное обращение — это несоответствие, которое не было выявлено до передачи результата потребителю [3]. Его последствия выходят за пределы стоимости повторной работы: снижается удовлетворённость клиента [4] и его готовность рекомендовать сервис, которую измеряют индексом NPS [5]. Автопроизводители давно используют обращения владельцев как

источник информации о качестве [6] и оценивают эффект мероприятий по повышению надёжности с учётом затрат на гарантийные ремонты и лояльности клиентов [7].

Самый надёжный способ не допустить повторного обращения — найти недоработку до того, как автомобиль покинул сервис: выполнить дополнительную проверку, тест-драйв, повторную диагностику. Однако проверять каждую машину дорого, а пост контроля имеет ограниченную пропускную способность. Поэтому возникает практическая задача: в момент закрытия заказ-наряда оценить вероятность повторного обращения и направлять на усиленный контроль только те автомобили, для которых риск высок.

Для такой оценки можно построить статистическую модель по накопленным заказ-нарядам. Но модель полезна сервису лишь тогда, когда понятно, насколько ей можно доверять и что именно означает её ошибка в цехе. Ответ на этот вопрос дают метрики качества прогноза. Метрик много, они отвечают на разные вопросы и при неудачном выборе легко создают ложное впечатление о модели. Поэтому значительная часть статьи посвящена тому, как каждая метрика переводится на язык сервиса: сколько машин придётся проверить, сколько будущих возвратов будет найдено, сколько проверок окажется напрасными.

Цель работы — построить прогноз риска повторного обращения в течение 30 дней после ремонта, выбрать способ прогноза по обоснованному набору метрик и дать сервису правило назначения усиленного контроля.

Описание данных

Исследование выполнено по данным одного из ведущих отечественных автопроизводителей. Массив содержит 3 000 закрытых заказ-нарядов. Каждая строка описывает один выполненный ремонт: насколько он был сложным и трудоёмким, сколько запчастей установлено, подтвердился ли первоначальный диагноз, какой стаж у мастера и к какому сегменту относится автомобиль. Целевой признак показывает, вернулся ли клиент с той же неисправностью в течение 30 дней. Состав признаков приведён в табл. 1.

Таблица 1

Признаки заказ-наряда

Признак	Содержание	Диапазон
Сложность ремонта	оценка по внутренней шкале сервиса, баллы	1–10
Трудоёмкость	фактические нормо-часы работ	0,5–20
Число запчастей	количество установленных запчастей	1–11
Подтверждение диагноза	первоначальный диагноз подтвердился в ходе работ (1) или нет (0)	0 / 1
Стаж мастера	стаж мастера, выполнявшего работы, лет	1–30
Сегмент автомобиля	1 — эконом, 2 — средний, 3 — премиум	1–3
Повторное обращение (целевой признак)	клиент вернулся с той же проблемой в течение 30 дней (1) или нет (0)	0 / 1

Принципиально важно, что все шесть признаков известны в момент закрытия заказ-наряда, то есть до выдачи автомобиля. Это позволяет применять прогноз именно тогда, когда ещё можно что-то исправить. Проверка данных показала, что пропусков и повторяющихся строк нет, а все значения лежат в допустимых диапазонах.

Повторно обратились 1 014 клиентов из 3 000, т. е. 33,8 %. Уже простой подсчёт долей по группам показывает, где сосредоточен риск. Если первоначальный диагноз подтвердился (2 051 заказ-наряд), возвращаются 14,9 % клиентов, а если не подтвердился (949 заказ-нарядов) — 74,7 %, т. е. три машины из четырёх. Доля возвратов растёт от

сегмента к сегменту примерно равными шагами: 30,1 % в эконом-сегменте, 35,7 % в среднем и 42,4 % в премиальном. Поэтому сегмент можно подавать в модель одним числом от 1 до 3.

Совместное влияние сложности ремонта и стажа мастера показано в табл. 2. При любой сложности опытные мастера допускают меньше повторных обращений, причём в абсолютных цифрах разница наибольшая на сложных ремонтах.

Таблица 2

Доля повторных обращений в зависимости от сложности ремонта и стажа мастера, %

Сложность ремонта	Стаж до 5 лет	5–10 лет	10–20 лет	20–30 лет
1–4 балла	27	23	18	9
4–7 баллов	47	39	36	26
7–10 баллов	67	63	46	42

Способы прогноза и порядок их проверки

Сравнивались два способа прогноза. Оба выдают для каждого заказ-наряда вероятность повторного обращения — число от 0 до 1.

Способ A — логистическая регрессия [8]. Модель складывает вклады всех признаков с весовыми коэффициентами и переводит сумму в вероятность. Её главное достоинство для инженера — объяснимость: по каждому коэффициенту можно сказать, во сколько раз меняются шансы возврата при изменении признака на единицу. Перед обучением признаки приводятся к единому масштабу.

Способ B — случайный лес [9]. Строится 100 деревьев решений глубиной не более шести уровней; каждое дерево задаёт последовательность вопросов вида «сложность больше 7 баллов?», «стаж меньше 5 лет?», а итоговая вероятность получается усреднением ответов всех деревьев. Случайный лес умеет находить нелинейные зависимости и взаимодействия признаков, которые логистическая регрессия не учитывает, но объяснить его прогноз заметно труднее. Ограничение глубины не даёт деревьям «заучить» обучающие данные.

Качество прогноза нельзя проверять на тех же заказ-нарядах, на которых модель обучалась: на знакомых данных любая модель выглядит лучше, чем будет работать на новых машинах [10]. Поэтому данные делились на обучающую часть (80 %, 2 400 заказ-нарядов) и проверочную (20 %, 600 заказ-нарядов), имитирующую поток новых автомобилей. Разбиение выполнялось с сохранением доли возвратов, чтобы в каждой проверочной части она была близка к 33,8 %. Параметры приведения признаков к единому масштабу рассчитывались только по обучающей части: иначе сведения о проверочных заказ-нарядах «просочились» бы в обучение и завысили оценку качества [11].

Результат одного разбиения зависит от того, какие заказ-наряды случайно попали в проверочную часть. Чтобы исключить этот случай, разбиение повторялось 100 раз с разными начальными значениями генератора случайных чисел. В каждом из 100 запусков оба способа обучались на одной и той же обучающей части и проверялись на одной и той же проверочной, после чего метрики усреднялись. Расчёты выполнены в среде Python с использованием библиотеки scikit-learn [12].

Метрики качества прогноза

Метрика качества — это ответ на вопрос «насколько хорошо модель справляется с задачей». Для сервиса этот вопрос распадается на несколько более конкретных: сколько

будущих возвратов модель находит, сколько проверок окажутся напрасными, можно ли верить самой вероятности, которую она выдаёт. Ни одна метрика не отвечает на все вопросы сразу [13], поэтому ниже каждая рассмотрена отдельно — с формулой, производственным смыслом и точкой отсчёта, с которой её надо сравнивать.

Решение «проверять / не проверять» и матрица ошибок

Модель выдаёт вероятность, а мастеру нужно решение. Решение получается сравнением вероятности с порогом: если вероятность не меньше порога, автомобиль направляется на усиленный контроль («тревога»), иначе выдаётся клиенту. При пороге 0,5 возможны четыре исхода, которые удобно свести в матрицу ошибок (табл. 3). Значения в таблице — средние по 100 запускам, пересчитанные на 100 закрытых заказ-нарядов.

Таблица 3

Матрица ошибок при пороге 0,5 (на 100 заказ-нарядов, среднее по 100 запускам)

Исход	Обозначение	Что происходит в сервисе	Способ А	Способ В
Пойманный возврат	TP	машина, которая вернулась бы, направлена на проверку	25,6	23,3
Ложная тревога	FP	проверена машина, которая и так не вернулась бы	5,1	3,4
Пропущенный возврат	FN	машина выдана без проверки и вернулась	8,2	10,5
Спокойная выдача	TN	машина выдана без проверки и не вернулась	61,1	62,8

Две ошибки имеют разную цену. Ложная тревога стоит времени поста контроля — одна лишняя проверка. Пропущенный возврат стоит повторного ремонта, недовольства клиента и удара по репутации сервиса. Все метрики, о которых идёт речь далее, — это разные способы свернуть четыре числа табл. 3 в одно.

Доля верных ответов (Accuracy) и её ловушка

Самая очевидная метрика — доля заказ-нарядов, по которым модель приняла правильное решение:

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}. \quad (1)$$

Для способа А она равна (25,6 + 61,1) / 100 = 0,867, для способа В — 0,861. Выглядит убедительно, однако эту цифру необходимо сравнить с прогнозом без модели. Если просто считать, что ни один клиент не вернётся, и никого не проверять, решение окажется верным для всех невернувшихся клиентов — в 66,2 % случаев. Такой «прогноз» не найдёт ни одного возврата, но его доля верных ответов всего на 20 процентных пунктов ниже, чем у модели. Чем реже встречается событие, тем сильнее эта ловушка: при доле возвратов 5 % «прогноз» «никто не вернётся» дал бы 95 % верных ответов. Поэтому доля верных ответов не может быть главной метрикой в задачах, где интересующих случаев заметно меньше, чем остальных [14].

Полнота (Recall) и доля найденных возвратов

Полнота показывает, какая доля клиентов, которые действительно вернутся, попала на усиленный контроль:

$$\text{Recall} = \frac{TP}{TP + FN}. \tag{2}$$

Для способа A Recall = 25,6 / (25,6 + 8,2) = 0,757: из каждых четырёх будущих возвратов модель находит три. Для руководителя сервиса это главный вопрос — сколько повторных обращений можно предотвратить. В медицинской статистике та же величина называется чувствительностью, а в построении ROC-кривой — долей истинно положительных решений (TPR).

Точность тревог (Precision) и доля обоснованных проверок

Точность тревог показывает, какая доля автомобилей, направленных на проверку, действительно вернулась бы:

$$\text{Precision} = \frac{TP}{TP + FP}. \tag{3}$$

Для способа A Precision = 25,6 / 30,7 = 0,835: из шести проверенных машин пять — действительно рискованные. Эта метрика отвечает на вопрос мастера поста контроля: не тратится ли его время впустую. Полнота и точность тревог тянут в разные стороны: чтобы найти больше возвратов, нужно проверять больше машин, и среди них неизбежно окажется больше благополучных.

Метрика F1 как компромисс полноты и точности

Чтобы выразить баланс полноты и точности одним числом, используют их гармоническое среднее:

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \tag{4}$$

Гармоническое среднее, в отличие от обычного, «наказывает» за провал одной из составляющих: модель, которая проверяет все машины подряд (Recall = 1, Precision = 0,338), получит F1 = 0,51, хотя обычное среднее дало бы 0,67. Для способа A F1 = 0,793, для способа B — 0,770. Недостаток F1 в том, что она молчаливо считает обе ошибки одинаково дорогими и не учитывает спокойные выдачи (TN).

Зависимость от порога

У всех четырёх метрик (1)–(4) есть общее свойство: они вычисляются при конкретном пороге. Сдвиньте порог — и изменятся все четыре числа. Например, при пороге 0,5 у способа B точность тревог выше (0,873 против 0,835), а полнота ниже (0,690 против 0,757). Это не означает, что один способ лучше другого: способ B просто осторожнее «поднимает тревогу» при этом пороге, и подбором порога у любого из двух способов можно получить любое соотношение полноты и точности. Поэтому для выбора способа нужны метрики, которые не зависят от порога, а сам порог должен выбираться отдельно, из производственных соображений.

ROC-кривая и площадь под ней (ROC-AUC)

ROC-кривая показывает работу модели сразу при всех порогах [15]. По вертикали откладывается доля пойманных возвратов (Recall, или TPR), по горизонтали — доля ложных тревог среди невернувшихся клиентов (FPR = FP / (FP + TN)). Каждый порог даёт одну точку

кривой (рис. 1). Для способа А при пороге 0,50 модель находит 75,7 % возвратов, поднимая ложную тревогу у 7,7 % благополучных клиентов; при пороге 0,35 — 83,7 % и 15,2 %; при пороге 0,20 — 90,4 % и 27,3 %. Диагональ соответствует случайному отбору машин на проверку: какую долю машин проверили, такую долю возвратов и нашли.

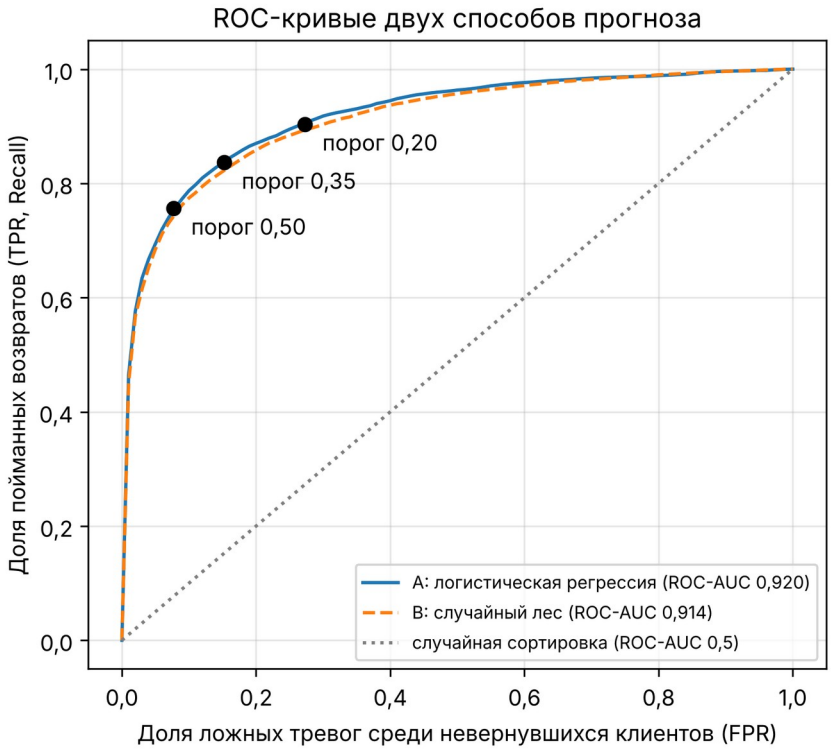


Рис. 1. ROC-кривые двух способов прогноза, усреднённые по 100 запускам. Точками отмечены пороги 0,20, 0,35 и 0,50 для способа А

Площадь под ROC-кривой (ROC-AUC) сворачивает всю кривую в одно число от 0,5 (случайный отбор) до 1 (идеальная модель). У неё есть простой и очень удобный для инженера смысл [16]: ROC-AUC равна вероятности того, что для случайно выбранной пары «клиент, который вернётся» — «клиент, который не вернётся» модель присвоит первому более высокий риск. Это было проверено непосредственно: в одном из запусков проверочная часть содержала 203 вернувшихся и 397 невернувшихся клиентов, т. е. 80 591 пару; модель правильно упорядочила 92,6 % пар, и ровно таким же оказалось значение ROC-AUC. Значение 0,92 означает: из 100 таких пар модель в 92 случаях ставит рискованный заказ-наряд выше благополучного.

ROC-AUC не зависит от порога и от доли возвратов в данных, поэтому она выбрана главной метрикой для сравнения способов. Её ограничение — она оценивает только порядок заказ-нарядов, но не то, насколько правдоподобны сами вероятности.

Оценка Брайера и достоверность прогнозной вероятности

Если мастеру сообщают «вероятность возврата 70 %», он вправе ожидать, что из десяти таких машин вернутся около семи. Насколько выдаваемые вероятности соответствуют действительности, показывает оценка Брайера [17] — средний квадрат разности между прогнозной вероятностью p_i и фактическим исходом y_i (1 — вернулся, 0 — нет):

$$BS = \frac{1}{n}\sum_{i=1}^{n}(p_i - y_i)^2. \tag{5}$$

Чем меньше оценка, тем лучше. Точкой отсчёта служит прогноз без модели, при котором каждому заказ-наряду приписывается средняя доля возвратов 0,338; его оценка равна 0,338 · 0,662 = 0,224. У способа A оценка Брайера 0,099, т. е. модель уменьшает ошибку вероятности на 56 % по сравнению с прогнозом без модели; у способа B — 0,105 (уменьшение на 53 %).

Наглядно соответствие вероятностей действительности видно из табл. 4: прогнозы способа A из всех 100 запусков разбиты на пять групп по величине вероятности, и в каждой группе средняя прогнозная вероятность сравнивается с фактической долей вернувшихся клиентов.

Таблица 4

Сравнение прогнозной вероятности с фактической долей повторных обращений (способ A)

Группа прогнозной вероятности	Доля заказ-нарядов в группе, %	Средняя прогнозная вероятность	Фактическая доля возвратов
0–0,2	51,4	0,057	0,063
0,2–0,4	12,8	0,290	0,238
0,4–0,6	9,6	0,496	0,456
0,6–0,8	7,8	0,703	0,723
0,8–1,0	18,3	0,929	0,954

Прогнозные вероятности близки к фактическим долям во всех группах; в средней части шкалы (0,2–0,6) модель немного завышает риск — на 4–5 процентных пунктов. Для решения «проверять / не проверять» такое расхождение несущественно, но его полезно иметь в виду, если вероятность будет сообщаться клиенту или использоваться в экономических расчётах. Отметим также, что половина заказ-нарядов получает вероятность ниже 0,2 и почти пятая часть — выше 0,8: модель уверенно разделяет большинство ремонтов на заведомо благополучные и заведомо рискованные.

Как учитывалась случайность разбиения

Каждая метрика вычислялась в каждом из 100 запусков; в таблицах приводятся среднее значение и стандартное отклонение. Стандартное отклонение показывает, насколько результат зависит от того, какие заказ-наряды попали в проверку. Обычный критерий Стьюдента для сравнения способов по 100 запускам здесь некорректен: проверочные части разных запусков пересекаются, запуски не независимы, и критерий завышает значимость различий [18, 19]. Поэтому способы сравнивались попарно: поскольку в каждом запуске оба способа проверялись на одних и тех же заказ-нарядах, подсчитывалось, в скольких запусках из 100 один способ оказался лучше другого.

Сводка метрик

Свойства рассмотренных метрик сведены в табл. 5. Она может служить памяткой при чтении любых отчётов о моделях прогноза брака, отказов или рекламаций.

Таблица 5

Метрики качества прогноза и их производственный смысл

Метрика	Вопрос, на который отвечает	Зависит от порога	Прогноз без модели	Способ А
Accuracy	какая доля решений верна	да	0,662	0,867
Recall	какая доля будущих возвратов найдена	да	0	0,757
Precision	какая доля проверок не напрасна	да	—	0,835
F1	баланс полноты и точности тревог	да	—	0,793
ROC-AUC	умеет ли модель ставить рискованные заказ-наряды выше благополучных	нет	0,5	0,920
Оценка Брайера	можно ли верить самой вероятности (меньше — лучше)	нет	0,224	0,099

Сравнение способов прогноза

Результаты 100 запусков приведены в табл. 6 и на рис. 2.

Таблица 6

Качество прогноза на проверочных частях (среднее ± стандартное отклонение по 100 запускам)

Метрика	Способ А (логистическая регрессия)	Способ В (случайный лес)
ROC-AUC	**0,920 ± 0,011**	0,914 ± 0,012
Оценка Брайера (меньше — лучше)	**0,099 ± 0,007**	0,105 ± 0,007
Recall (порог 0,5)	**0,757 ± 0,032**	0,690 ± 0,034
Precision (порог 0,5)	0,835 ± 0,026	**0,873 ± 0,026**
F1 (порог 0,5)	**0,793 ± 0,022**	0,770 ± 0,025
Accuracy (порог 0,5)	**0,867 ± 0,013**	0,861 ± 0,014

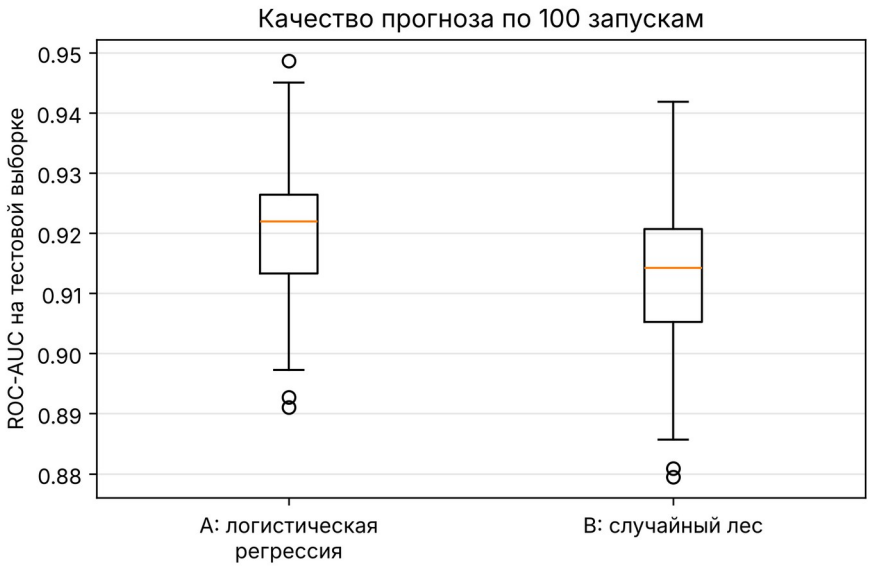


Рис. 2. Разброс ROC-AUC двух способов прогноза по 100 запускам

По обеим метрикам, не зависящим от порога, способ А лучше. Средняя разница ROC-AUC невелика — 0,007, и разброс каждого способа от запуска к запуску (около 0,011–0,012) больше этой разницы. Однако попарное сравнение показывает, что преимущество

устойчиво: по ROC-AUC способ А лучше в 97 запусках из 100, по оценке Брайера — в 99 из 100. Различия по полноте и точности тревог при пороге 0,5, как показано выше, отражают положение порога, а не качество способов.

Почему более сложный способ не дал выигрыша, видно из табл. 2. При любом стаже мастера доля возвратов растёт со сложностью ремонта, а при любой сложности снижается с ростом стажа. Факторы действуют каждый в своём направлении и просто складываются, без неожиданных сочетаний вида «опасно только при такой-то сложности и таком-то стаже». Именно такую картину и описывает логистическая регрессия, поэтому случайному лесу, который умеет искать сложные сочетания, найти в этих данных больше нечего. Этот результат согласуется с выводами систематического обзора [20], в котором для задач прогноза на табличных данных умеренного объёма не выявлено преимущества сложных методов машинного обучения перед логистической регрессией. Для практики выбран способ А: он не уступает по качеству, проще во внедрении и, главное, объясним.

Влияние факторов на риск повторного обращения

Для объяснения прогноза логистическая регрессия была обучена на всех 3 000 заказ-нарядах в исходных единицах признаков (баллы, часы, годы). Эта модель используется только для интерпретации; качество прогноза оценено выше на проверочных частях. Влияние каждого фактора выражено отношением шансов $OR = e^{\beta}$, где β — коэффициент регрессии [8]. Шансы — это отношение «вернётся / не вернётся»: при доле возвратов 33,8 % шансы равны 0,338 / 0,662 ≈ 0,5. Отношение шансов больше 1 означает, что фактор повышает риск, меньше 1 — снижает. Результаты приведены в табл. 7 и на рис. 3.

Таблица 7

Влияние факторов на шансы повторного обращения (факторы упорядочены по силе влияния)

Фактор	Изменение фактора	Отношение шансов (95 %-й интервал)	Производственный смысл
Подтверждение диагноза	нет → да	0,011 (0,008–0,015)	при неподтверждённом диагнозе шансы возврата выше примерно в 90 раз
Сложность ремонта	+1 балл	1,81 (1,71–1,92)	каждый балл сложности увеличивает шансы в 1,8 раза
Стаж мастера	+1 год	0,919 (0,906–0,933)	каждый год стажа снижает шансы на 8 %, 10 лет — в 2,3 раза
Трудоёмкость	+1 нормо-час	1,11 (1,08–1,13)	каждый нормо-час увеличивает шансы на 11 %
Сегмент автомобиля	+1 ступень	1,67 (1,43–1,96)	у премиального сегмента шансы в 2,8 раза выше, чем у эконом-сегмента
Число запчастей	+1 запчасть	1,16 (1,09–1,24)	каждая запчасть увеличивает шансы на 16 %

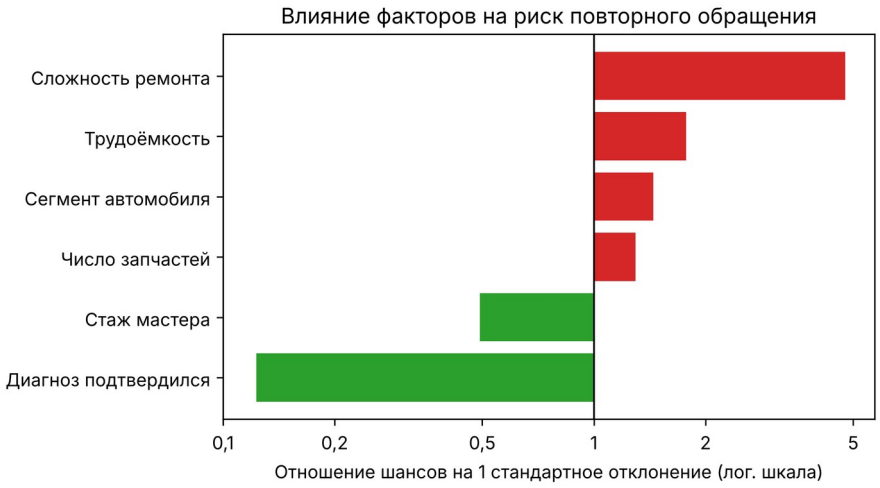


Рис. 3. Сила влияния факторов: отношение шансов при изменении фактора на одно стандартное отклонение (логарифмическая шкала; правее единицы — фактор повышает риск, левее — снижает)

Все доверительные интервалы не накрывают единицу, т. е. влияние каждого фактора статистически значимо. Порядок факторов проверен независимо: случайный лес выделяет те же три главных фактора — подтверждение диагноза (доля в общей важности 0,575), сложность ремонта (0,243) и стаж мастера (0,078).

Отношение шансов для диагноза требует пояснения. Значение «примерно в 90 раз» получено при прочих равных условиях, т. е. для заказ-нарядов с одинаковой сложностью, трудоёмкостью, стажем мастера и т. д. В простых долях картина выглядит так: при неподтверждённом диагнозе возвращаются 75 % клиентов, при подтверждённом — 15 %, т. е. в 5 раз чаще. Для разговора с персоналом сервиса удобнее именно доли, а отношение шансов нужно для сравнения факторов между собой.

Выбор порога усиленного контроля

Метрики, не зависящие от порога, позволили выбрать способ прогноза. Теперь нужно выбрать сам порог — и это уже не математическое, а управленческое решение. Низкий порог позволяет найти больше будущих возвратов, но требует проверять больше машин. В табл. 8 и на рис. 4 для способа А приведены средние по 100 запускам значения в пересчёте на 100 закрытых заказ-нарядов. Именно в таком виде результаты прогноза понятны руководителю сервиса: вместо «Recall 0,84 при FPR 0,15» — «проверяем 38 машин из 100 и находим 84 % будущих возвратов».

Таблица 8

Последствия выбора порога (способ А, на 100 закрытых заказ-нарядов)

Порог	Направляем на контроль, машин	Из них вернулись бы	Найдено возвратов (Recall), %	Пропущено возвратов	Точность тревог (Precision), %
0,20	48,6	30,6	90,4	3,3	63
0,30	41,3	29,2	86,2	4,7	71
0,35	38,4	28,3	83,7	5,5	74
0,40	35,8	27,5	81,3	6,3	77
0,50	30,7	25,6	75,7	8,2	83
0,60	26,2	23,1	68,4	10,7	88

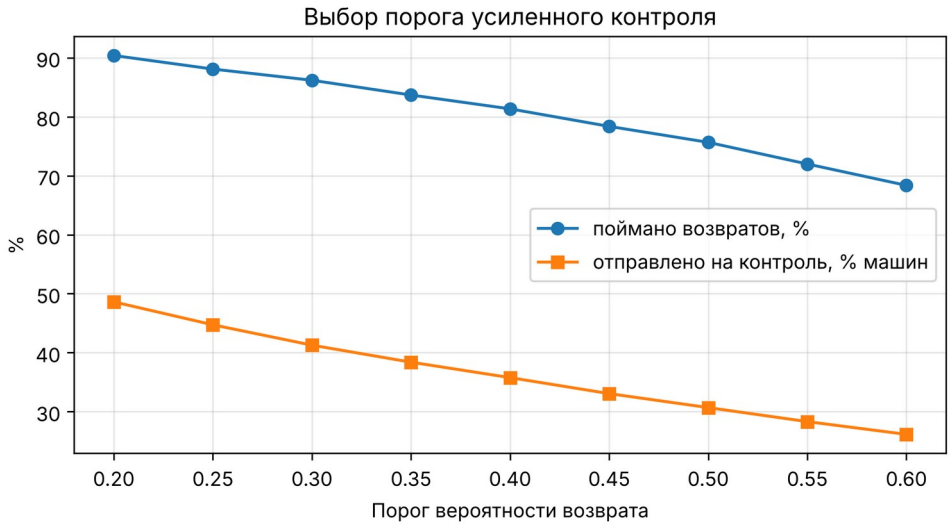


Рис. 4. Доля найденных повторных обращений и доля автомобилей, направленных на контроль, при разных порогах (способ А, среднее по 100 запускам)

Ценность модели хорошо видна при сравнении с выборочной проверкой без модели. Если случайно отобрать на проверку 38 машин из 100, среди них окажется около 38 % будущих возвратов; при отборе тех же 38 машин по прогнозу модели (порог 0,35) — 84 %. Иначе говоря, при той же загрузке поста контроля модель позволяет найти более чем вдвое больше недоработок.

Табл. 8 показывает и цену каждого дополнительно найденного возврата. При снижении порога с 0,50 до 0,35 число проверок растёт на 7,7 на 100 заказ-нарядов, а число найденных возвратов — на 2,7, т. е. на каждый дополнительно найденный возврат приходится около трёх дополнительных проверок. При снижении порога с 0,35 до 0,20 — уже 10,2 проверки на 2,3 найденных возврата, т. е. четыре-пять проверок на один возврат. Чем ниже порог, тем дороже каждый следующий найденный возврат.

Если известны стоимость одной проверки $C_{\text{пр}}$ и стоимость одного повторного ремонта с учётом потерь лояльности $C_{\text{рем}}$, а проверка устраняет выявленную недоработку, то экономически обоснованный порог равен [21]

$$t^{*} = \frac{C_{\text{пр}}}{C_{\text{пр}} + C_{\text{рем}}}. \qquad (6)$$

Например, если повторный ремонт обходится в четыре раза дороже проверки, порог равен 1 / (1 + 4) = 0,2. Формула (6) опирается на то, что прогнозные вероятности соответствуют действительности, — именно поэтому оценка Брайера и табл. 4 важны не только для отчёта, но и для практики. Если же фактическим ограничением служит пропускная способность поста контроля, порог выбирается по табл. 8: например, пост, способный принять около 40 машин из каждых 100 закрытых заказ-нарядов, соответствует порогу 0,30–0,35.

У полученных оценок есть ограничения. Модель построена на одном массиве из 3 000 заказ-нарядов, поэтому перед внедрением её необходимо проверить на свежих данных конкретного сервиса. Порог требует уточнения по фактической загрузке поста контроля и реальным затратам на проверку и повторный ремонт. Наконец, модель указывает на риск, но сама не предотвращает возврат: эффект достигается только тогда, когда усиленный контроль действительно выявляет и устраняет недоработку.

Практические рекомендации

На основании полученных результатов для сервиса можно сформулировать следующие рекомендации.

1. **Неподтверждённый диагноз — всегда повод для усиленного контроля.** Если в ходе работ первоначальный диагноз не подтвердился, клиент возвращается в трёх случаях из четырёх. Такой автомобиль следует направлять на дополнительную проверку и тест-драйв независимо от прогноза модели.

2. **Сложные ремонты — опытным мастерам.** При сложности 7–10 баллов у мастеров со стажем до 5 лет возвращаются 67 % клиентов, со стажем 20–30 лет — 42 % (табл. 2). Распределение сложных заказ-нарядов с учётом стажа исполнителя снижает число возвратов там, где их больше всего.

3. **Расчёт вероятности — в процедуру закрытия заказ-наряда.** Все признаки модели известны до выдачи автомобиля, поэтому вероятность возврата может рассчитываться автоматически при закрытии заказ-наряда. Если она не ниже выбранного порога, автомобиль до выдачи проходит усиленный контроль. Порог устанавливает руководитель сервиса по табл. 8 с учётом пропускной способности поста или по формуле (6), если известны затраты.

4. **Сообщать результаты персоналу в машинах, а не в метриках.** Для руководителя и мастеров значение «ROC-AUC 0,92» ничего не говорит; формулировка «проверяем 38 машин из 100 и находим 84 % будущих возвратов, без модели нашли бы 38 %» понятна каждому и позволяет сразу оценить нагрузку на пост.

5. **Контролировать работу модели после внедрения по двум простым показателям.** Ежемесячно следует считать долю повторных обращений, которые до выдачи были направлены на усиленный контроль (полнота), и долю проверок, при которых обнаружена недоработка (точность тревог). Заметное снижение любого из них, а также расхождение прогнозной вероятности с фактической долей возвратов (как в табл. 4) — сигнал к переобучению модели на свежих данных.

Заключение

1. Поставлена и решена практическая задача сервиса автомобилей: в момент закрытия заказ-наряда оценить вероятность повторного обращения клиента с той же неисправностью в течение 30 дней и на этой основе назначать усиленный контроль качества до выдачи автомобиля.

2. Показано, что при оценке прогноза сервису важно выбрать правильный показатель. Доля верных ответов вводит в заблуждение: прогноз «никто не вернётся» даёт 66 % верных ответов, не находя ни одного возврата. Для выбора порога проверки нужны полнота (какую долю будущих возвратов найдём) и точность тревог (какая доля проверок не напрасна). Для выбора способа прогноза нужны показатели, не зависящие от порога: ROC-AUC, которая показывает, в скольких парах «вернётся — не вернётся» модель верно указывает рискованную машину, и оценка Брайера, которая показывает, можно ли верить самой вероятности.

3. Логистическая регрессия оказалась немного, но устойчиво точнее случайного леса: ROC-AUC 0,920 против 0,914 (лучше в 97 запусках из 100), оценка Брайера 0,099 против 0,105 (лучше в 99 запусках из 100). Для сервиса выбрана логистическая регрессия: она не

уступает по качеству и позволяет объяснить мастеру, почему конкретная машина попала в группу риска.

4. Главные факторы повторного обращения — неподтверждённый в ходе работ диагноз (возвращаются 75 % клиентов против 15 %), сложность ремонта и стаж мастера.

5. Результаты прогноза переведены на язык загрузки поста контроля: при пороге 0,35 на проверку направляются 38 автомобилей из 100 и среди них оказываются 84 % будущих повторных обращений, тогда как выборочная проверка того же числа машин выявила бы около 38 %. Применять прогноз предлагается так: при закрытии заказ-наряда рассчитывается вероятность возврата, и если она не ниже порога, автомобиль до выдачи проходит дополнительную проверку и тест-драйв. Порог выбирает руководитель сервиса по пропускной способности поста или по соотношению затрат на проверку и повторный ремонт.

Список литературы

1. О защите прав потребителей : закон Рос. Федерации от 07.02.1992 № 2300-1 // Ведомости Съезда народных депутатов Рос. Федерации и Верховного Совета Рос. Федерации. – 1992. – № 15. – Ст. 766.

2. Об утверждении Правил оказания услуг (выполнения работ) по техническому обслуживанию и ремонту автомототранспортных средств : постановление Правительства Рос. Федерации от 29.05.2025 № 780 // Собрание законодательства Рос. Федерации. – 2025. – № 22 (ч. I). – Ст. 2897.

3. ГОСТ Р ИСО 9001–2015. Системы менеджмента качества. Требования. – Введ. 2015–11–01. – М. : Стандартинформ, 2020.

4. ГОСТ Р ИСО 10004–2020. Менеджмент качества. Удовлетворенность потребителей. Руководящие указания по мониторингу и измерению. – Введ. 2021–04–01. – М. : Стандартинформ, 2020.

5. Reichheld F.F. The one number you need to grow // Harvard Business Review. – 2003. – Vol. 81, № 12. – P. 46–54, 124.

6. Разработка систем обратной связи с потребителями в управлении качеством и надежностью автомобилей в период эксплуатации / В.Н. Козловский, Р.А. Малеев, Е.В. Полякова, В.И. Коротков // Известия МГТУ «МАМИ». – 2014. – Т. 8, № 2-1. – С. 37–41. – DOI 10.17816/2074-0530-67662.

7. Комплекс аналитических инструментов оценки эффективности мероприятий направленных на улучшение надежности автомобилей / В.Н. Козловский, Р.А. Малеев, Д.И. Панюков, Л.А. Кудинова // Известия МГТУ «МАМИ». – 2014. – Т. 8, № 2-1. – С. 31–36. – DOI 10.17816/2074-0530-67653.

8. Hosmer D.W., Lemeshow S., Sturdivant R.X. Applied Logistic Regression. – 3rd ed. – Hoboken : Wiley, 2013. – 500 p.

9. Breiman L. Random forests // Machine Learning. – 2001. – Vol. 45, № 1. – P. 5–32. – DOI 10.1023/A:1010933404324.

10. Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. – 2nd ed. – New York : Springer, 2009. – 745 p.

11. Leakage in data mining: formulation, detection, and avoidance / S. Kaufman, S. Rosset, C. Perlich, O. Stitelman // ACM Transactions on Knowledge Discovery from Data. – 2012. – Vol. 6, № 4. – Art. 15. – DOI 10.1145/2382577.2382579.

12. Scikit-learn: Machine Learning in Python / F. Pedregosa [et al.] // Journal of Machine Learning Research. – 2011. – Vol. 12. – P. 2825–2830.

13. Assessing the performance of prediction models: a framework for traditional and novel measures / E.W. Steyerberg [et al.] // Epidemiology. – 2010. – Vol. 21, № 1. – P. 128–138. – DOI 10.1097/EDE.0b013e3181c30fb2.

14. Saito T., Rehmsmeier M. The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets // PLoS ONE. – 2015. – Vol. 10, № 3. – Art. e0118432. – DOI 10.1371/journal.pone.0118432.

15. Fawcett T. An introduction to ROC analysis // Pattern Recognition Letters. – 2006. – Vol. 27, № 8. – P. 861–874. – DOI 10.1016/j.patrec.2005.10.010.

16. Hanley J.A., McNeil B.J. The meaning and use of the area under a receiver operating characteristic (ROC) curve // Radiology. – 1982. – Vol. 143, № 1. – P. 29–36.

17. Brier G.W. Verification of forecasts expressed in terms of probability // Monthly Weather Review. – 1950. – Vol. 78, № 1. – P. 1–3. – DOI 10.1175/1520-0493(1950)078<0001:VOFEIT>2.0.CO;2.

18. Nadeau C., Bengio Y. Inference for the generalization error // Machine Learning. – 2003. – Vol. 52, № 3. – P. 239–281. – DOI 10.1023/A:1024068626366.

19. Dietterich T.G. Approximate statistical tests for comparing supervised classification learning algorithms // Neural Computation. – 1998. – Vol. 10, № 7. – P. 1895–1923. – DOI 10.1162/089976698300017197.

20. A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models / E. Christodoulou [et al.] // Journal of Clinical Epidemiology. – 2019. – Vol. 110. – P. 12–22. – DOI 10.1016/j.jclinepi.2019.02.004.

21. Elkan C. The foundations of cost-sensitive learning // Proceedings of the Seventeenth International Joint Conference on Artificial Intelligence (IJCAI 2001). – Seattle, 2001. – P. 973–978.

Фрелих Иван Павлович, аспирант кафедры «Управление качеством и стандартизация», ivan.frelikh@yandex.ru, Россия, Самара, Самарский государственный технический университет,

Мосин Владимир Геннадьевич, д-р техн. наук, канд. физ.-мат. наук, доцент кафедры «Высшая математика», yanbacha@yandex.ru, Россия, Самара, Самарский государственный технический университет

PREDICTING THE RISK OF A REPEAT VISIT AFTER VEHICLE REPAIR, PREDICTION QUALITY METRICS AND THE CHOICE OF THE ENHANCED INSPECTION THRESHOLD

I.P. Frelikh, V.G. Mosin

The paper addresses a practical task of a car service: at the moment a work order is closed, estimate the probability that the customer will return with the same problem within 30 days, and assign an enhanced quality inspection to high-risk vehicles before they are handed over. A dataset of 3,000 closed work orders provided by one of the leading Russian automakers, with a repeat-visit rate of 33.8 % is analysed. Two prediction methods, logistic regression and random forest, are compared over 100 independent random train/test splits. Particular attention is paid to prediction quality metrics: for accuracy, recall, precision, F1, ROC-AUC and the Brier score it is shown which practical question each metric answers, which no-model baseline it should be compared with, and why accuracy is misleading when classes are unequal. Logistic regression proved slightly but consistently better than the random forest: ROC-AUC 0.920 ± 0.011 vs 0.914 ± 0.012 (better in 97 of 100 runs) and Brier score 0.099 vs 0.105 (better in 99 of 100 runs). The main driver of repeat visits is an initial diagnosis not confirmed during the repair: such customers return in 75 % of cases versus 15 %. The metrics are translated into inspection-station workload: at a threshold of 0.35, 38 vehicles out of 100 are sent for inspection and they include 84 % of future repeat visits, whereas a random inspection of the same number of vehicles would catch about 38 %.

Key words: vehicle maintenance and repair, repeat visit, repair quality, enhanced inspection, logistic regression, random forest, classification quality metrics, ROC-AUC, Brier score, decision threshold.

Frelikh Ivan Pavlovich, postgraduate, ivan.frelikh@yandex.ru, Russia, Samara, Samara State Technical University,

Mosin Vladimir Gennadievich, doctor of technical sciences, candidate of physical and mathematical sciences, docent, yanbacha@yandex.ru, Russia, Samara, Samara State Technical University